

APLICAÇÃO DE CONTROLADOR PREDITIVO BASEADO EM MODELO COM RESTRIÇÕES A UM COMPRESSOR INDUSTRIAL

Francisco F. L. Freitas¹, Wilkley B. Correia¹, Davi N. Oliveira¹, Otacílio da M. Almeida¹, José G. e Silva²

¹GPAR - Grupo de Pesquisa em Automação e Robótica,

¹LAMOTRIZ - Laboratório de Eficiência Energética em Sistemas Motrizes Industriais,
Departamento de Engenharia Elétrica, Centro de Tecnologia, Universidade Federal do Ceará,
Campus do Pici, Caixa Postal 6001 – CEP 60.455-760 Fortaleza, CE, Brasil

²GPSA - Grupo de Pesquisa em Separações por Adsorção

Departamento de Engenharia Química, Centro de Tecnologia, Universidade Federal do Ceará
Campus do Pici - Bloco 710, Fortaleza, CE, Brasil

E-mails: {fabiolobo, wilkley, davi, otacilio}@dee.ufc.br, msgilson@uol.com.br

Resumo – Atualmente o cenário mundial exige que as plantas industriais operem em condição de eficiência energética. A fim de alcançar este objetivo, nos últimos anos a academia tem concentrado esforços para tornar esta tarefa possível. A área de controle e automação tem tido um peso significativo neste assunto, especialmente nas aplicações que funcionam com os controladores preditivos para sistemas com não-linearidades. Neste artigo propõe-se o uso de uma ferramenta de Controle Preditivo Baseado em Modelo (MBPC - “Model Based Predictive Control”) com restrições aplicadas a uma planta industrial de um compressor.

Palavras-Chaves – Aquisição de Dados, Controle Preditivo, Restrições.

Abstract – Nowadays the world scenario claims for industrial plants operating under energetic efficiency. In order to meet this goal, through the last years academy had devoted efforts to make it possible. The Control and Automation area had been a significant weight on this matter, specially on applications running with predictive controllers for systems with non-linearity. This paper is intended to propose an application by the use of MBPC – “Model Based Predictive Control” tool with constraints applied to an industrial compressor plant.

Keywords – Constraints, Data acquisition, Predictive Control.

I. INTRODUÇÃO

Sistemas industriais é um campo vasto para aplicações de técnicas de controle e suas aplicações têm ajudado na eficiência energética, na otimização de processos ou em aspectos tangentes ao custo operacional.

Para uma grande parcela das aplicações industriais o controle preditivo baseado em modelos (MBPC – “Model Based Predictive Control”) constitui a estratégia de controle adotada. O termo MBPC descreve uma classe de algoritmos computacionais de controle que, a partir de previsões baseadas em um modelo do processo, controla o comportamento futuro através da minimização de uma função objetivo. A tecnologia MBPC foi originalmente aplicada em sistemas de potência e refinarias petrolíferas. Atualmente, podem ser encontrados MBPC's em uma variedade de ambientes de manufatura, incluindo-se químicos, processamento de alimentos, automotivos, aeroespacial, metalúrgico e fabricação de papel [1]. Segundo pesquisa, realizada nas indústrias japonesas [2], controladores preditivos baseados em modelos, competem com as estratégias de controle PID convencional e com o controle nebuloso no que se refere ao número de malhas de processos controlados e quanto ao grau de satisfação dos usuários. Do ponto de vista prático, os controladores preditivos superam deficiências dos controladores clássicos quando utilizados no controle de sistemas complexos caracterizados por atrasos de transportes, parâmetros variantes no tempo, mudança na ordem do modelo, fase não-mínima, e erros de modelagens [3, 4, 5, 6, 7].

No que se refere a modelagem de sistemas uma aproximação linearizada do modelo pode ser aceitável para a maioria das malhas. Contudo, para alguns sistemas com fortes não linearidades a linearização pode resultar em modelos com pobres desempenhos. A título de exemplos, alguns destes sistemas altamente não lineares incluem controle de pH em alguns processos químico ou biomédico, controle de espessura em máquinas de laminar na indústria metalúrgica ou o controle de temperatura reator de batelada com controle de faixa dividido [6].

Este artigo apresenta uma proposta de controle preditivo com restrição aplicada a compressores industriais.

Compressores industriais são plantas caracterizadas por não linearidades de fraca a moderadas e que frequentemente quando controladas através de algoritmos convencionais do tipo PID apresentam saturações.

Para efeito de avaliação da estratégia, o sistema é controlado a partir do MATLABTM/Simulink que conta com uma ferramenta poderosa na montagem de sistemas de controle preditivo: *Model Predictive Control Toolbox*TM 2. Resultados de implementações são comparados à uma implementação de um controlador PI clássico, apresentando-se os resultados obtidos ao final. Este trabalho está dividido como segue: na seção II apresenta-se uma descrição da ferramenta computacional utilizada, na seção III descreve-se o modelo da planta considerada e métodos para sua obtenção e na seção IV apresentam-se as comparações e resultados.

II. DESCRIÇÃO DA FERRAMENTA

O uso do MATLABTM/Simulink em sistemas de engenharia para simulação de controle tem sido largamente difundido na comunidade científica. O sucesso consolidado desta aplicação despertou o interesse de pesquisadores em desenvolver ferramentas computacionais a serem aplicadas nas mais diversas áreas. Uma dessas ferramentas, denominada *Model Predictive Control Toolbox*TM 2. e proposta por Bemporad *et al.* foi o objeto utilizado para as simulações da planta, nesse caso a planta descrita na seção III. Trata-se, portanto, de uma ferramenta computacional para predição e otimização, idealizada por seus autores de acordo com a Figura 1[8].

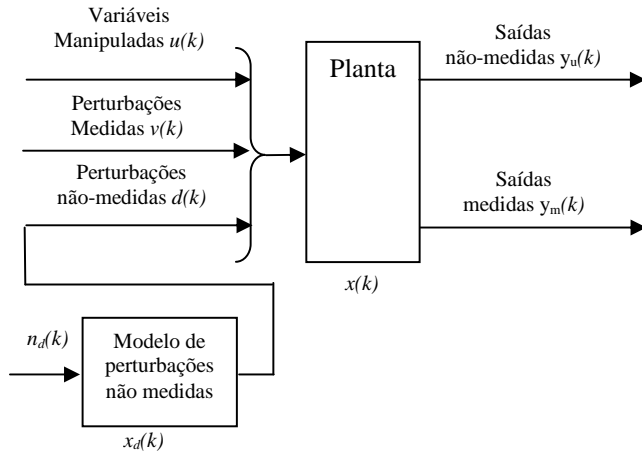


Fig.1. Modelo considerado pelo toolbox.

Os sistemas considerados para a planta e para as perturbações são do tipo LTI e estão descritos conforme (1) e (2). Mais detalhes sobre a descrição da ferramenta, incluindo-se o tratamento matemático abordado, podem ser encontrados em [8].

$$\begin{cases} x(k+1) = Ax(k) + B_u u(k) + B_v v(k) + B_d d(k) \\ y_m(k) = C_m x(k) + D_{vm} v(k) + D_{dm} d(k) \\ y_u(k) = C_u x(k) + D_{vu} v(k) + D_{du} d(k) + D_{uu} u(k) \end{cases} \quad (1)$$

Onde:

- $x(k)$ – vetor n_x -dimensional de estado da planta;
- $u(k)$ – vetor n_u -dimensional da variável manipulada;
- $v(k)$ – vetor n_v -dimensional das perturbações medidas;
- $d(k)$ – vetor n_d -dimensional das perturbações não-medidas;
- $y_m(k)$ – vetor das saídas medidas;
- $y_u(k)$ – vetor das saídas não-medidas;

$$\begin{cases} x_d(k+1) = \bar{A}x_d(k) + \bar{B}n_d(k) \\ d(k) = \bar{C}x_d(k) + \bar{D}n_d(k) \end{cases} \quad (2)$$

e a função objetivo é dada por (3).

$$\begin{aligned} \min_{\Delta u(k|k), \dots, \Delta u(m-1+k|k), \epsilon} & \left\{ \sum_{i=0}^{p-1} \left[\sum_{j=1}^{n_y} |w_{i+1,j}^y (y_j(k+1+i|k) - r_j(k+1+i))|^2 \right. \right. \\ & + \sum_{j=1}^{n_u} |w_{i,j}^{\Delta u} \Delta u_j(k+1|k)|^2 \\ & \left. \left. + \sum_{j=1}^{n_u} |w_{i,j}^u (u_j(k+1|k) - u_{j \text{ arg et}}(k+i))^2 + \rho_\epsilon \epsilon^2 \right\} \end{aligned} \quad (3)$$

As restrições em u , Δu e y são função direta da variável $\epsilon \geq 0$ e o peso ρ_ϵ , dado por (4), é a variável que torna (3) com solução possível ou não. Se esse peso torna-se excessivamente alto, dificilmente (3) poderá ser minimizada, resultando em um valor máximo de entrada e, portanto, saída igualmente saturada em um valor máximo[8].

$$\rho_\epsilon = 10^5 \max\{w_{i,j}^{\Delta u}, w_{i,j}^u, w_{i,j}^y\} \quad (4)$$

As restrições de entrada e saída são normalizadas de modo que 0 significa não violação de restrições enquanto 1 corresponde ao maior grau de violação. O padrão é que todas as variáveis de entrada que possuam restrição em 0 e todas as saídas em 1[8].

O algoritmo implementado utiliza procedimentos diferentes dependendo da presença ou não de restrições. No caso da inexistência de restrições, a variável ϵ é retirada de (3) e a função custo é resolvida de modo analítico. Caso contrário, o algoritmo utilizado implementa programação quadrática, onde as matrizes associadas ao problema são aquelas descritas a seguir[8].

A. Modelo de Predição

Aplicando-se a expressão de $d(k)$ apresentada em (2) na expressão de $x(k+1)$ mostrado em (1), chega-se a:

$$\begin{aligned} x &= \begin{bmatrix} x \\ x_d \end{bmatrix} \\ A &= \begin{bmatrix} A & B_d \bar{C} \\ 0 & \bar{A} \end{bmatrix} \end{aligned}$$

$$\begin{aligned}
B_u &= \begin{bmatrix} B_u \\ 0 \end{bmatrix}, B_v = \begin{bmatrix} B_v \\ 0 \end{bmatrix}, B_d = \begin{bmatrix} B_d \overline{D} \\ \overline{B} \end{bmatrix} \\
C &= [C \quad D_d \overline{C}] \\
D_{v_m} &= \begin{bmatrix} D_{v_m} \\ 0 \end{bmatrix}, D_{n_d} = \begin{bmatrix} D_{d_m} \overline{D} \\ 0 \end{bmatrix}
\end{aligned} \quad (5)$$

A partir das matrizes encontradas em (5) chega-se a uma expressão da saída $y(i)$ e de $\Delta u(i)$ [8].

$$\begin{bmatrix} y(1) \\ \dots \\ y(p) \end{bmatrix} = S_x x(0) + S_{u1} u(-1) + S_u \begin{bmatrix} \Delta u(0) \\ \dots \\ \Delta u(p-1) \end{bmatrix} + H_v \begin{bmatrix} v(0) \\ \dots \\ v(p) \end{bmatrix} \quad (6)$$

Onde:

$$S_x = \begin{bmatrix} CA \\ CA^2 \\ \dots \\ CA^p \end{bmatrix} \in \mathbb{R}^{pn_y \times n_x} \quad S_{u1} = \begin{bmatrix} CB_u \\ CB_u + CAB_u \\ \dots \\ \sum_{h=0}^{p-1} CA^h B_u \end{bmatrix} \in \mathbb{R}^{pn_y \times n_u}$$

$$S_u = \begin{bmatrix} CB_u & 0 & \dots & 0 \\ CB_u + CAB_u & CB_u & \dots & 0 \\ \dots & \dots & \dots & \dots \\ \sum_{h=0}^{p-1} CA^h B_u & \sum_{h=0}^{p-2} CA^h B_u & \dots & CB_u \end{bmatrix} \in \mathbb{R}^{pn_y \times n_u} \quad (7)$$

$$H_v = \begin{bmatrix} CB_v & D_v & 0 & \dots & 0 \\ CAB_v & CB_v & D_v & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ CA^{p-1} B_v & CA^{p-2} B_v & CA^{p-3} B_v & \dots & D_v \end{bmatrix}$$

$$e \quad \begin{bmatrix} \Delta u(0) \\ \dots \\ \Delta u(p-1) \end{bmatrix} = J_M \begin{bmatrix} z_0 \\ \dots \\ z_{m-1} \end{bmatrix} \quad (8)$$

No caso de escolherem-se J_M e Z em (8) iguais aos vetores mostrado em (9) geram-se os sinais mostrados na Figura 2. [8]

$$J_M = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}; Z = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad (9)$$





Fig. 2. Exemplo de movimentos dos sinais de controle $u(k)$ e variação do sinal de controle $\Delta u(k)$.

Considerando-se a função custo dada por (10).

$$J(z, \epsilon) = \begin{bmatrix} u(0) \\ \dots \\ u(p-1) \end{bmatrix} - \begin{bmatrix} u_{target}(0) \\ \dots \\ u_{target}(p-1) \end{bmatrix}^T W_u^2 \begin{bmatrix} u(0) \\ \dots \\ u(p-1) \end{bmatrix} - \begin{bmatrix} u_{target}(0) \\ \dots \\ u_{target}(p-1) \end{bmatrix} + \begin{bmatrix} \Delta u(0) \\ \dots \\ \Delta u(p-1) \end{bmatrix}^T W_{\Delta u}^2 \begin{bmatrix} \Delta u(0) \\ \dots \\ \Delta u(p-1) \end{bmatrix} + \begin{bmatrix} y(1) \\ \dots \\ y(p) \end{bmatrix} - \begin{bmatrix} r(1) \\ \dots \\ r(p) \end{bmatrix}^T W_y^2 \begin{bmatrix} y(1) \\ \dots \\ y(p) \end{bmatrix} - \begin{bmatrix} r(1) \\ \dots \\ r(p) \end{bmatrix} \quad (10)$$

Onde:

$W_{(\cdot)}$ - matrizes diagonais correspondentes aos pesos de entrada ($u(t)$), da variação da entrada ($\Delta u(t)$) e da saída ($y(t)$) [8].

Assim, de posse dos sinais $u(k)$, $\Delta u(k)$ e $y(k)$, chega-se a $J(z)$ conforme indicado em (10) [8].

$$J(z, \epsilon) = \rho_\epsilon \epsilon^2 + z^T K_{\Delta u} z + 2 \begin{bmatrix} r(1) \\ \dots \\ r(p) \end{bmatrix}^T K_r + \begin{bmatrix} v(0) \\ \dots \\ v(p) \end{bmatrix}^T K_v + u(-1)^T K_u + \begin{bmatrix} u_{target}(0) \\ \dots \\ u_{target}(p-1) \end{bmatrix}^T K_{ut} + x(0)^T K_x \Big\} z + cte \quad (11)$$

Onde:

$K_{(\cdot)}$ - matrizes Hessianas que aparecem ao substituir-se $u(k)$, $\Delta u(k)$ e $y(k)$ em (3) [8].

A expressão (11) é aquela que será minimizada.

III. MODELO DA PLANTA UTILIZADA

A planta a ser controlada é um sistema de compressão pertencente ao Laboratório de Eficiência Energética em Sistemas Motrizes Industriais (LAMOTRIZ) da UFC. Este sistema é composto por um compressor que é acionado por um motor de indução trifásico (MIT) de 3Hp, que pode ser acionado tanto pela rede elétrica quanto por um inversor de frequência de 2,5 kW do modelo Altivar31 da *Schneider-Eletric*.

O compressor desse sistema é do tipo parafuso com um acoplamento de correias do tipo V entre o MIT e a câmara de compressão. A Figura 3 mostra o diagrama esquemático da bancada experimental [9].

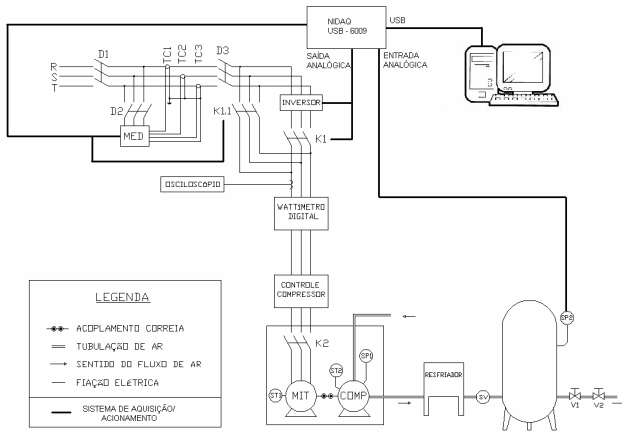


Fig. 3. Diagrama esquemático do sistema de compressão.

O sistema em questão foi modelado por 2 métodos distintos: o método dos mínimos quadrados e o método da curva reativa.

A. Método dos Mínimos Quadrados

O método dos mínimos quadrados (MQ) foi primeiramente formulado por Karl Friedrich Gauss no final do século XVIII para prever a trajetória dos planetas e cometas baseado em observações realizadas[10].

Considere o sistema proposto sendo representado da seguinte forma:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix}, \quad (12)$$

$$\mathbf{y} = \mathbf{x}\boldsymbol{\theta} \quad (12)$$

onde $\mathbf{x} \in \mathcal{R}^{n \times n}$ e x_i é a i -ésima coluna de \mathbf{x} . Na equação (11), \mathbf{y} é a *variável dependente*, pois depende dos *regressores*, x_1, \dots, x_n , que são também denominados *variáveis independentes*. E por fim, $\boldsymbol{\theta}$ é o vetor de parâmetros a ser determinado. Caso a matriz \mathbf{x} seja não

singular, é possível calcular o vetor de parâmetros $\boldsymbol{\theta}$ da seguinte forma:

$$\boldsymbol{\theta} = \mathbf{x}^{-1}\mathbf{y} \quad (13)$$

O método dos mínimos quadrados consiste em estimar o vetor de parâmetros $\boldsymbol{\theta}$ [11]. De posse do vetor de parâmetros estimados $\hat{\boldsymbol{\theta}}$, e do erro cometido $\boldsymbol{\varepsilon}$ ao se tentar encontrar \mathbf{y} a partir do vetor de regressores \mathbf{x} e de $\hat{\boldsymbol{\theta}}$, tem-se:

$$\mathbf{y} = \mathbf{x}\hat{\boldsymbol{\theta}} + \boldsymbol{\varepsilon} \quad (14)$$

sendo que $\boldsymbol{\varepsilon} \in \mathcal{R}^n$ é o vetor de erros cometidos.

Definindo-se J_{MQ} como sendo o somatório dos erros quadráticos, tem-se

$$J_{MQ} = \sum_{i=1}^n \varepsilon(i)^2 = \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} = \|\boldsymbol{\varepsilon}\|^2 \quad (15)$$

Assim, isolando-se $\boldsymbol{\varepsilon}$ na equação (13) e substituindo-se em (14) fica

$$J_{MQ} = \mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{x}\hat{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}}^T \mathbf{x}^T \mathbf{y} + \hat{\boldsymbol{\theta}}^T \mathbf{x}^T \mathbf{x}\hat{\boldsymbol{\theta}} \quad (16)$$

Para minimizar a equação (15) deve-se calcular a derivada da equação em relação à $\hat{\boldsymbol{\theta}}$, o que resulta:

$$\hat{\boldsymbol{\theta}}_{MQ} = [\mathbf{x}^T \mathbf{x}]^{-1} \mathbf{x}^T \mathbf{y} \quad (17)$$

Para o sistema de compressão em questão foi estimado um sistema de 1ª ordem, cujos parâmetros encontrados foram:

$$\hat{\boldsymbol{\theta}}_{MQ} = [-0.9770 \quad 0.0249] \quad (18)$$

A partir destes parâmetros a função de transferência modelada do sistema de compressão real é:

$$G(s) = \frac{0.005038}{s + 0.004654} \quad (19)$$

B. Método da Curva Reativa

O método da curva reativa nada mais é do que obter a resposta no tempo do sistema $y(t)$ a um degrau $u(t)$ como mostra a Figura 4. De posse dessa resposta temporal, os parâmetros do processo da equação (19) abaixo pode ser obtidos através da medição de dois tempos, t_1 sendo o tempo que a saída $y(t)$ atinge 28.3% de seu valor de regime permanente e t_2 quando $y(t)$ atinge 63.2% [12].

$$G(s) = \frac{K}{1 + \tau s} e^{-s\tau_d} \quad (20)$$

Os parâmetros do processo são dados por:

$$K = \frac{\Delta y}{\Delta u}, \quad \tau = 1.5(t_2 - t_1), \quad \tau_d = (t_1 - \frac{1}{3}t_2) \quad (21)$$




Fig. 4. Figura da curva reativa [12].

Calculando-se os valores de t_1 e t_2 , resultou nos seguintes valores de K , τ e τ_d :

$$\begin{aligned} K &= 0.004208 \\ \tau &= 0.003918 \\ \tau_d &= 0 \end{aligned} \quad (22)$$

O que resulta na seguinte função de transferência:

$$G(s) = \frac{0.004208}{s + 0.003918} \quad (23)$$

C. Descrição dos Controladores

Foram considerados dois controladores para a análise da planta, um MPC e um PI.

O controlador MPC considerado foi do tipo SISO (*Single Input Single Output*) com uma entrada (sinal de controle do inversor), uma saída (pressão no vaso) e restrições nas variáveis de controle e de saída.

O controlador PI considerado foi um PID onde não se fez uso da parcela derivativa.

A função de transferência considerada para os cálculos tanto dos parâmetros PI quanto dos ajustes nos parâmetros do MPC foi a obtida através do método dos mínimos quadrados (19).

Para o caso do controlador PI obteve-se um ganho proporcional (K_p) igual a 10 e um ganho integral (K_i) igual 0,015, considerando-se erro de regime próximo a zero. Esses valores foram obtidos através de cálculo da equação de malha fechada do sistema, considerando-se $G(s)$ mostrado em (19).

Para o controlador MPC os parâmetros considerados foram:

- Horizonte de controle: 5;
- Horizonte de predição: 30;
- Peso da variável de controle $u(t)$ - W_u em (10): 0;
- Peso de $\Delta u(t)$ - $W_{\Delta u}$ em (10): 0,9;

- Peso da saída - W_y em (10): 1;
- Restrição na variável de entrada: 4,6;
- Restrição na variável de saída: 2;
- Peso total das restrições - ε em (3): 0,5;

A escolha dos horizontes de controle e predição foi feita em função das respostas da planta observadas, conforme recomendado em [12]. As demais variáveis seguiram a mesma orientação, como também é sugerido em [8].

Os ambientes montados são ilustrados nas Figuras 5 e 6.




Fig. 5. Arranjo em simulink do controlador PI.

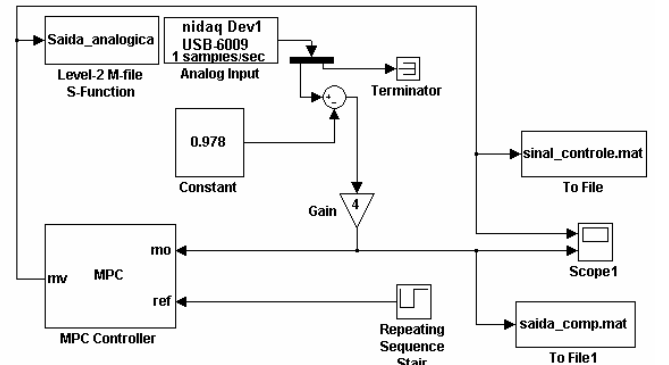


Fig. 6. Arranjo em simulink do controlador MPC.

Em ambos os modelos foi necessário que se considerasse uma subtração de 0,978 multiplicando-se por um ganho de 4 logo a seguir, simplesmente para adequar-se o fundo de escala do sensor de pressão àquele da placa de aquisição de dados.

Vale a pena ressaltar que os valores obtidos para a variável de resposta (sinal proveniente do sensor de pressão do vaso) são mostrados em tensão e não em bar. Portanto, onde se observa uma restrição, por exemplo, de 2, isto representa, aproximadamente, 3,8 bar.

IV. CONCLUSÕES

Ao final deste trabalho, verificou-se que o controlador MPC montado utilizando-se o bloco disponível no *Model Predictive Control Toolbox™ 2* do MATLAB™/Simulink mostrou resultados satisfatórios, que podem ser comprovados pelos gráficos da Figura 7. Nele é possível evidenciar-se que o controlador PI de fato controlou a pressão no nível de referência desejado, enquanto o MPC não ultrapassou o valor ajustado para restrição.

O sinal de controle para o MPC, comparado com o mesmo do PI está ilustrado na Figura 8. Observa-se que o sinal de controle do MPC não ultrapassa 4,6 porque essa foi a restrição considerada na variável de controle.

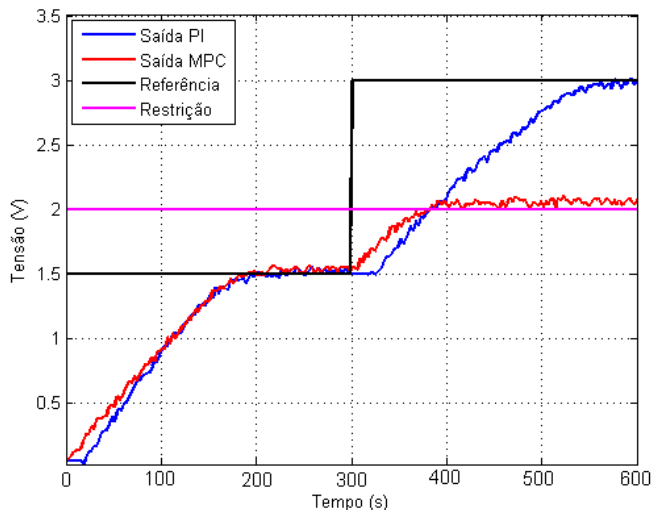


Fig. 7. Sinal de saída (pressão no vaso) para ambos os controladores.

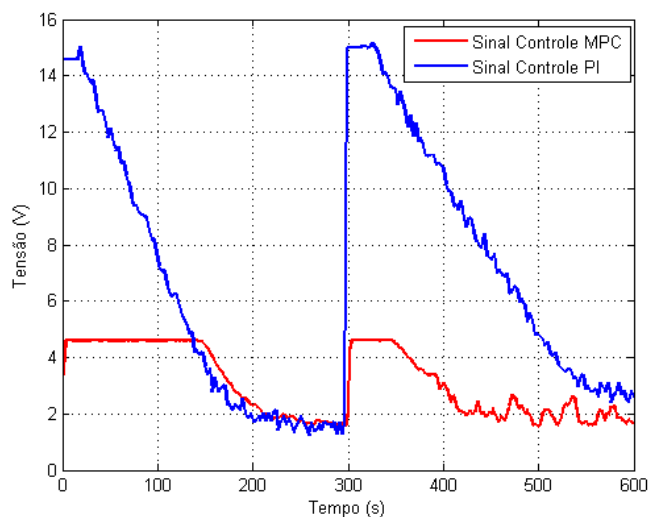


Fig. 8. Sinais de controle MPC e PI.

Neste momento, os estudos são no sentido de se observar os efeitos do peso global das restrições na resposta do sistema, ou seja, como afetam o comportamento da variável de controle bem como a resposta do sistema. Realiza-se também uma ampla revisão bibliográfica de modo a aprofundar mais os conhecimentos de controle preditivo com restrições, para que se possa incluir um modelo de estimação da planta em um mesmo programa de um controlador MPC.

AGRADECIMENTOS

A equipe envolvida nesta pesquisa agradece à Universidade Federal do Ceará, a FUNCAP pelo apoio financeiro, ao Laboratório de Eficiência Energética em Sistemas Motrizes Industriais (LAMOTRIZ) da UFC e à Eletrobrás.

REFERÊNCIAS

[1] Qin, S. J.; Badgwell, T. J.; "An Overview of Nonlinear Model Predictive Control Applications", International

Symposium on Nonlinear Model Predictive Control Workshop - Assessment and Future Directions, 1998. Preprints.

- [2] Takatsu H., Itoh, T., "Future Needs for Control Theory in Industry - Report of the Control technology Survey in Japanese Industry", IEEE Transaction on Control Systems Technology, 1999, v. 37, n. 3, p. 298-305.
- [3] Guibé, J. B., Vaucoret, C.; "Robust Multivariable Predictive Control - An Application to an Industrial Plant Stand", IEEE Control Systems Magazine, 2001, p. 54-65.
- [4] Demircioglu, H., Karasu, E.; (2000). Generalized Predictive Control: A Practical Application and Comparison of Discrete and Continuous Time Versions, IEEE Control Systems Magazine, p. 36-47.
- [5] Reis, Laurinda L. Nogueira, Coelho, A.A.R.C., Almeida, O. M., Carvalho, R. N., Self-Tuning Controller For Switched Reluctance Motor Based On Generalized Minimum Variance Method, VII International Conference On Industrial Application, VII INDUSCON, 2006.
- [6] Diniz, Eber de Castro; Almeida, Otacilio da Mota; Barreto, L. H. S. C. A new predictive control of water conductivity using a microcontroller applied to off-set printing; IEEE International Symposium on Industrial Electronics, 2007. ISIE 2007, 2007, Vigo, Espanha. Proceedings of the IEEE International Symposium on Industrial Electronics, 2007, 2007. v. 1.
- [7] Andrade, F. V.; DANIEL, Almeida O. M.; Controle Preditivo de Trajetória de Robô Móvel Implementado por Redes Neurais; Anais do VIII Congresso Brasileiro de Redes Neurais (CBRN), 2007, Florianópolis. VIII Congresso Brasileiro de Redes Neurais (CBRN). Florianópolis: Sociedade Brasileira de Redes Neurais (SBRN), 2007. v. 1. p. 1-6.
- [8] Model Predictive Control Toolbox™ 2 - User's Guide. Bemporad, A., Morari, A., Ricker, N. L.
- [9] Aguiar, V. P. B. Estudo de Eficiência Energética no Acionamento de um Compressor Parafuso em um Sistema de Ar Comprimido. Dissertação (Mestrado) - DEE/UFC - Universidade Federal do Ceará, Campus do Pici S/N, Fev 2008.
- [10] Coelho, A. A. R. and Coelho, L. d. S. (2004). Identificação de Sistemas Dinâmicos Lineares, 2a edição, Editora da UFSC.
- [11] Aguirre, L. A. (2004). Introdução à Identificação de Sistemas, 2a edição, Editora da UFSC.
- [12] Camacho, E. F., and Bordons, C., Model Predictive Control. Springer-Verlag, 1999.

BIOGRAFIAS

Francisco F. L. Freitas possui graduação em Engenharia Elétrica pela Universidade Federal do Ceará (2006). Atualmente está cursando o mestrado em Engenharia Elétrica na Universidade Federal do Ceará e pesquisador do Grupo de Pesquisa em Automação e Robótica (GPARG). Tem experiência na área de Engenharia Elétrica, com ênfase em Controle de Sistemas, atuando principalmente nos seguintes temas: Inteligência Computacional, Identificação de Sistemas, Controle de Processos, Controladores Preditivos e Controladores Inteligentes.

Wilkey B. Correia possui graduação em Engenharia Elétrica pela Universidade Federal da Paraíba (1998) e especialização em Engenharia de Telecomunicações pela Universidade Federal do Ceará (2005). Atualmente está cursando o mestrado em Engenharia Elétrica na Universidade Federal do Ceará. Tem experiência na área de Engenharia Elétrica, com ênfase em Controle de Sistemas, atuando principalmente nos seguintes temas: Identificação de Sistemas, Controle de Processos, Controladores Preditivos e Controladores Inteligentes.

Otacílio da M. Almeida possui graduação em Engenharia Elétrica pela Universidade Federal do Ceará (1987), mestrado em Engenharia Elétrica pela Universidade Estadual de Campinas (1990) e doutorado em Engenharia Elétrica pela Universidade Federal de Santa Catarina (2002). Atualmente é Professor Adjunto II da Universidade Federal do Ceará. Tem experiência na área de Engenharia Elétrica, com ênfase em Eletrônica Industrial, Sistemas e Controles Eletrônicos. Atuando principalmente nos seguintes temas: Controle de Processos, Controladores Inteligentes, Controladores PID, controladores nebulosos, Controladores Preditivo e Controle Industrial.

Davi N. Oliveira possui graduação em Engenharia de Controle e Automação-Mecatrônica pela Universidade de Fortaleza (2007). Atualmente está cursando o mestrado em Engenharia Elétrica na Universidade Federal do Ceará. Atua principalmente nos seguintes temas: mecatrônica,

controlador lógico programável (CLP), sistema supervisório, microcontrolador.

José G. e Silva possui graduação em Engenharia Química pela Universidade Federal da Bahia (1976), especialização em Engenharia de Processamento Petroquímico (1976) (convênio Petrobrás/UFBA). Publicou diversos trabalhos em congressos no Brasil e no Japão. Lecionou na UFBA, Cefet-Ba e Senai. Atualmente está cursando o mestrando em Engenharia Química na Universidade Federal do Ceará, trabalha como consultor de empresas e Prof. do Curso de Pós-graduação da Unifor, Prof. Substituto do Curso de Eng. Química da UFC (desde 2007). Atuação nas áreas de engenharia de processo, projeto, montagem, meio ambiente, qualidade, laboratório, ensino, produção, pesquisa tecnológica (através de convênios com Ufba, Ufsc, Usp, Ufrj) e suprimento, ocupando diversos cargos técnicos e de gestão.